

TABLE DE MATIÈRE

<i>TABLE DE FIGURES:</i>	3
<i>Introduction</i>	4
<i>Objectifs du Projet</i>	6
<i>Construction de la Base de Données Oncologique</i>	8
<i>Génération de Données Synthétiques</i>	10
<i>Module NLP</i>	11
<i>Conception et Architecture du système</i>	12
Architecture globale du système	12
Pipeline RAG : flux d'exécution.....	13
Langage de Programmation Principal	14
Backend.....	14
Frontend.....	14
Pipeline de Données et NLP	15
Sentence-Transformers / Hugging Face Transformers.....	15
Modèles de Langage (LLM).....	16
Outils de Développement et Gestion de Projet	16
Formats de Données Utilisés	17
Conclusion.....	17
<i>Module de Retrieval</i>	17
<i>Architecture RAG</i>	18
<i>Modèles de Langage Utilisés (LLM)</i>	19
<i>Évaluation du Système</i>	21
<i>Interface Web</i>	23
<i>Limites du Projet</i>	31
<i>Conclusion</i>	32

TABLE DE FIGURES:

Figure 1: Architecture globale de système.....	12
Figure 2: Pipeline RAG-flux d'exécution	13
Figure 3: FASTAPI.....	14
Figure 4: UNICORN	14
Figure 5: Pydantic	14
Figure 6:REACTJS	14
Figure 7: VITE.....	15
Figure 8: Tailwind CSS	15
Figure 9 : Évaluation de la recherche (retrieval).....	21
Figure 10 : Évaluation de la génération (LLM).....	22
Figure 11 :Assistant	23
Figure 12:Assistant Avec Resources.....	24
Figure 13 : Historique	24
Figure 14 : Documents.....	25
Figure 15 : Statistiques	26
Figure 16:Benchmark LLM.....	27
Figure 17 :Évaluation Retrieval.....	28
Figure 18 : Traitement Hybride.....	29
Figure 19 : Parcours Patient.....	29
Figure 20 : Profil	30

Introduction

L'intelligence artificielle (IA) et le traitement automatique du langage naturel (Natural Language Processing - NLP) occupent aujourd'hui une place centrale dans la transformation numérique du secteur de la santé. Ces technologies permettent de concevoir des systèmes capables de comprendre, analyser et générer du texte en langage naturel, facilitant ainsi l'accès à l'information médicale et l'aide à la prise de décision.

Dans le domaine de l'oncologie, les connaissances médicales sont particulièrement riches et complexes. Les protocoles thérapeutiques regroupent des informations détaillées sur le diagnostic des cancers, les classifications, les stratégies de traitement, les protocoles de chimiothérapie, ainsi que le suivi des patients. Ces documents sont essentiels pour les professionnels de santé, mais leur compréhension peut être difficile pour les non-spécialistes, notamment les patients, en raison de leur caractère technique et de la densité des informations.

Au Maroc, les protocoles oncologiques sont définis à partir de références officielles telles que le Guide des Protocoles Thérapeutiques en Oncologie publié par l'AMFROM. Ces ressources constituent une base fiable et standardisée pour la prise en charge des patients atteints de cancer. Cependant, leur consultation peut s'avérer longue et complexe, ce qui limite parfois leur accessibilité dans des situations nécessitant une réponse rapide et claire.

Par ailleurs, les grands modèles de langage (Large Language Models - LLMs) ont montré des performances remarquables dans la génération de texte et la compréhension du langage naturel. Toutefois, ils présentent une limite importante dans les domaines sensibles comme la médecine : ils peuvent générer des réponses non vérifiées ou imprécises, connues sous le nom d'hallucinations. Cette problématique rend leur utilisation directe risquée dans un contexte médical.

Pour répondre à ce défi, les architectures Retrieval-Augmented Generation (RAG) ont été proposées. Cette approche combine un système de recherche d'information et un modèle de génération, permettant d'appuyer les réponses sur des documents fiables et vérifiables. Le système récupère d'abord les informations pertinentes dans une base de connaissances, puis génère une réponse structurée et contextualisée.

L'objectif de ce projet est de développer un assistant médical intelligent spécialisé en oncologie, basé sur une architecture NLP et RAG. Le système doit être capable de répondre à des questions en langage naturel en s'appuyant sur une base de données construite à partir de références marocaines. Les réponses générées doivent être claires, pédagogiques et adaptées aussi bien aux professionnels de santé qu'aux patients.

Ainsi, ce projet vise à exploiter les techniques modernes de NLP et de recherche d'information afin de rendre les protocoles oncologiques plus accessibles, tout en garantissant la fiabilité des réponses fournies par le système.

Problématique

Les documents médicaux spécialisés en oncologie constituent une source essentielle de connaissances pour la compréhension et la prise en charge des cancers. Ils regroupent un ensemble d'informations complexes couvrant plusieurs aspects fondamentaux tels que le diagnostic des cancers, les examens cliniques et paracliniques nécessaires, les protocoles thérapeutiques recommandés, les effets secondaires des traitements ainsi que le suivi des patients tout au long de leur parcours de soins. Ces informations sont indispensables pour garantir une prise en charge médicale conforme aux standards scientifiques et aux recommandations officielles.

Cependant, malgré leur importance, ces documents présentent plusieurs limites en termes d'accessibilité et d'exploitation. Tout d'abord, les informations sont souvent dispersées dans différents guides, chapitres ou protocoles, ce qui rend leur consultation longue et fastidieuse. Ensuite, le langage utilisé est généralement technique et destiné à un public spécialisé, ce qui rend la compréhension difficile pour les étudiants, les jeunes praticiens ou les patients souhaitant s'informer sur leur état de santé. Enfin, la recherche manuelle d'une information précise dans un document volumineux peut s'avérer inefficace, notamment dans un contexte où le temps constitue un facteur critique.

Dans ce contexte, le principal défi consiste à exploiter efficacement ces ressources médicales afin de les rendre plus accessibles, plus structurées et plus faciles à consulter. Il ne s'agit pas uniquement de retrouver une information, mais également de la présenter sous une forme compréhensible et adaptée au profil de l'utilisateur. En effet, un même contenu médical doit pouvoir être interprété différemment selon qu'il s'adresse à un oncologue, à un étudiant en médecine ou à un patient.

Par ailleurs, l'émergence des grands modèles de langage (LLMs) a ouvert de nouvelles perspectives dans le domaine des systèmes conversationnels intelligents. Ces modèles sont capables de répondre à des questions complexes en langage naturel et de générer des explications détaillées. Toutefois, ils présentent une limite importante dans les domaines sensibles tels que la médecine : ils peuvent produire des réponses incorrectes ou non vérifiées, phénomène connu sous le nom d'hallucination. Dans un contexte médical, ce type d'erreur peut entraîner des interprétations erronées et compromettre la fiabilité de l'information fournie.

Ainsi, la problématique centrale de ce projet réside dans la conception d'un système intelligent capable de combiner compréhension du langage naturel, recherche d'information fiable et génération de réponses pédagogiques. Ce système doit être en mesure de traiter des questions médicales formulées en langage naturel, de rechercher les informations pertinentes dans une base de connaissances spécialisée construite à partir de références marocaines, puis de reformuler ces informations de manière claire, structurée et adaptée à l'utilisateur.

De plus, le système doit être capable de fournir des réponses cohérentes et fiables en évitant toute génération d'informations non fondées. Cela implique l'intégration de mécanismes de récupération d'information précis et d'une architecture capable de s'appuyer uniquement sur des sources validées. L'objectif est donc de garantir un équilibre entre accessibilité de l'information, précision médicale et sécurité des réponses générées.

En résumé, ce projet s'inscrit dans une démarche visant à améliorer l'accès aux connaissances oncologiques en exploitant les techniques modernes de NLP et les architectures de type Retrieval-Augmented Generation (RAG), tout en répondant aux contraintes de fiabilité et de compréhension dans le domaine médical.

Objectifs du Projet

L'objectif général de ce projet est de concevoir et de développer un assistant conversationnel intelligent spécialisé en oncologie. Ce système repose sur les techniques modernes de traitement automatique du langage naturel (NLP) et sur l'architecture Retrieval-Augmented Generation (RAG). Il a pour vocation de fournir des réponses fiables, structurées et pédagogiques à partir de protocoles médicaux marocains officiels, tout en facilitant leur compréhension par différents types d'utilisateurs, notamment les professionnels de santé et les patients.

Dans ce contexte, le projet vise à répondre à un besoin concret : l'accès rapide, clair et fiable à des informations médicales complexes issues de documents spécialisés en oncologie. Afin d'atteindre cet objectif global, plusieurs objectifs spécifiques ont été définis.

Tout d'abord, il est nécessaire de construire une base de connaissances oncologique personnalisée. Cette base constitue le cœur du système et regroupe des informations structurées à partir de références médicales marocaines. Elle inclut différents types de cancers, leurs méthodes de diagnostic, les protocoles thérapeutiques associés, les effets secondaires des traitements ainsi que les parcours de soins. Cette étape est essentielle pour garantir la qualité et la pertinence des réponses générées par le système.

Ensuite, les informations issues des documents médicaux doivent être reformulées de manière claire et structurée. L'objectif est de transformer un contenu technique et parfois complexe en une version plus accessible, tout en conservant la précision scientifique. Cette reformulation permet d'adapter les connaissances médicales à différents profils d'utilisateurs et d'améliorer la compréhension globale des protocoles oncologiques.

Un autre objectif important consiste à mettre en place un système de recherche hybride basé sur BM25 et les embeddings. Cette approche permet de combiner la recherche lexicale traditionnelle avec la recherche sémantique. Ainsi, le système est capable de retrouver des informations pertinentes même lorsque les questions des utilisateurs sont formulées différemment des documents sources. L'utilisation des embeddings permet notamment de capturer le sens des phrases, tandis que BM25 améliore la précision basée sur les mots-clés.

Le projet vise également à développer un pipeline complet de type Retrieval-Augmented Generation (RAG). Ce pipeline permet d'intégrer plusieurs étapes essentielles : analyse de la requête utilisateur, récupération des documents pertinents, enrichissement du contexte, puis génération de la réponse à l'aide d'un modèle de langage. Cette architecture garantit que les réponses produites sont basées sur des sources fiables et réduisent le risque de génération d'informations incorrectes.

Par ailleurs, une étape importante du projet consiste à comparer plusieurs modèles de langage (Large Language Models - LLMs). Cette comparaison permet d'évaluer les performances de différents modèles en termes de pertinence des réponses, de qualité de la génération et de cohérence avec les documents fournis. L'objectif est d'identifier le modèle le plus adapté au domaine médical et aux contraintes du système.

Le développement d'une interface web interactive constitue également un objectif clé. Cette interface permet aux utilisateurs de poser des questions en langage naturel, de consulter les réponses générées et d'interagir avec le système de manière simple et intuitive. Elle joue un rôle essentiel dans l'accessibilité du système et dans l'expérience utilisateur globale.

Enfin, le projet prévoit la possibilité d'ajouter de nouvelles sources documentaires de manière flexible. Cette extensibilité permet d'enrichir progressivement la base de connaissances avec de nouveaux

protocoles, mises à jour médicales ou documents spécialisés, garantissant ainsi la pérennité et l'évolution du système dans le temps.

En résumé, ces objectifs visent à concevoir un système intelligent complet, combinant NLP, recherche d'information et génération de texte, afin de faciliter l'accès aux connaissances oncologiques tout en garantissant leur fiabilité et leur pertinence.

Construction de la Base de Données Oncologique

La première étape fondamentale de ce projet a consisté à concevoir et construire une base de connaissances oncologique personnalisée. Cette base constitue le cœur du système RAG, car elle permet de fournir des réponses fiables, structurées et adaptées aux requêtes des utilisateurs. Elle a été élaborée à partir de documents médicaux officiels marocains, notamment les protocoles thérapeutiques en oncologie.

Contrairement à une approche classique consistant à importer directement des documents PDF dans un système de Retrieval-Augmented Generation, une démarche plus rigoureuse a été adoptée. Chaque protocole médical a été soigneusement étudié, compris et analysé avant d'être reformulé manuellement. Cette étape de reformulation a été essentielle afin de respecter les contraintes pédagogiques du projet, d'éviter le copier-coller direct et de garantir la création d'une base de données originale, claire et adaptée à un usage intelligent.

La base de connaissances construite couvre un ensemble représentatif des principaux types de cancers rencontrés dans la pratique oncologique. Elle inclut notamment le cancer du sein, le cancer du poumon, le cancer colorectal, le cancer de la prostate, le cancer de l'ovaire, le cancer du col de l'utérus, ainsi que les hémopathies malignes telles que les lymphomes et les leucémies. Ces pathologies ont été sélectionnées en raison de leur fréquence et de leur importance dans les protocoles thérapeutiques marocains.

Pour chaque type de cancer, les informations ont été organisées de manière structurée afin de faciliter leur exploitation par le système de recherche et de génération. Plusieurs catégories de données ont été définies afin de couvrir l'ensemble du parcours médical du patient. Ces catégories incluent principalement le diagnostic, la classification tumorale, les stratégies thérapeutiques, la chimiothérapie, la radiothérapie, les thérapies ciblées, l'immunothérapie, le suivi médical, les effets secondaires des traitements ainsi que le pronostic.

Cette structuration permet de représenter de manière cohérente les différentes étapes de la prise en charge oncologique, depuis l'identification de la maladie jusqu'au suivi post-thérapeutique. Elle facilite également la recherche d'information précise dans le cadre du système RAG, en améliorant la granularité des données et la pertinence des résultats récupérés.

Chaque entrée de la base de données a été construite selon un format standardisé afin d'assurer l'uniformité et l'efficacité du système de retrieval. Ainsi, chaque enregistrement contient un identifiant unique permettant de l'identifier de manière précise, le type de cancer associé, la catégorie d'information (diagnostic, traitement, suivi, etc.), ainsi qu'une description reformulée en langage clair et structuré. À cela s'ajoutent des mots-clés pertinents facilitant la recherche, le stade clinique lorsqu'il est applicable, le protocole thérapeutique associé, des cas d'usage permettant de contextualiser l'information, ainsi que la référence documentaire d'origine.

Cette approche permet de transformer des données médicales complexes en une base de connaissances exploitable par des algorithmes de recherche sémantique et lexicale. Elle garantit également une meilleure adaptabilité aux requêtes des utilisateurs, qu'il s'agisse de questions générales ou de cas cliniques spécifiques.

En complément des données issues des protocoles officiels, des données synthétiques ont également été générées afin d'enrichir la base de connaissances. Ces données incluent des scénarios patients

fictifs, des variations de formulation des questions médicales, ainsi que des cas cliniques représentant différents stades de la maladie ou des situations particulières. Cette diversification améliore la robustesse du système et sa capacité à généraliser face à des requêtes variées.

Ainsi, la construction de cette base de données oncologique constitue une étape essentielle du projet, car elle garantit la qualité des informations utilisées par le système RAG et conditionne directement la pertinence des réponses générées par l'assistant médical.

Génération de Données Synthétiques

Afin d'améliorer la qualité, la robustesse et la couverture de la base de connaissances oncologique, une étape importante du projet a consisté à générer des données synthétiques. Cette démarche vise à compléter les informations issues des protocoles médicaux officiels en introduisant des variations linguistiques, des scénarios cliniques fictifs et des cas d'usage diversifiés. L'objectif principal est d'augmenter la capacité du système RAG à généraliser face à des requêtes utilisateur variées et parfois imprécises.

Dans un contexte réel d'utilisation, les utilisateurs peuvent formuler leurs questions de nombreuses manières différentes, même lorsqu'ils recherchent la même information médicale. Par exemple, une question relative au traitement du cancer du sein peut être exprimée sous plusieurs formes linguistiques tout en conservant le même sens. Afin de garantir une bonne performance du système de retrieval, il est donc essentiel d'entraîner ou d'alimenter la base de connaissances avec des formulations variées et représentatives.

La première catégorie de données synthétiques générées concerne les scénarios patients fictifs. Ces scénarios permettent de simuler des situations cliniques réalistes afin de contextualiser les informations médicales. Par exemple, un cas peut décrire un patient de 52 ans présentant une masse mammaire palpable, sans antécédents familiaux connus. Les examens d'imagerie révèlent une lésion suspecte nécessitant une biopsie. Ce type de scénario permet de relier les données théoriques des protocoles à des situations concrètes, facilitant ainsi leur exploitation dans un contexte d'assistance médicale.

La deuxième catégorie concerne les variations de questions médicales. Cette étape consiste à reformuler une même requête de différentes manières afin d'enrichir la capacité du système à comprendre les intentions des utilisateurs. Par exemple, la question initiale « Quel est le traitement du cancer du sein ? » peut être reformulée sous plusieurs formes telles que : « Comment traite-t-on un cancer du sein ? », « Quels sont les protocoles utilisés pour le cancer mammaire ? » ou encore « Quelles sont les options thérapeutiques disponibles pour le cancer du sein ? ». Ces variations permettent d'améliorer la robustesse du module de retrieval en renforçant la correspondance entre les requêtes utilisateur et les documents de la base de connaissances.

Enfin, une troisième catégorie de données synthétiques a été intégrée afin de couvrir des cas cliniques complexes. Ces cas incluent des situations médicales particulières telles que la présence de métastases osseuses ou hépatiques, ainsi que des profils de patients présentant des comorbidités comme le diabète, l'hypertension artérielle ou un âge avancé. L'intégration de ces cas complexes permet de simuler des situations réalistes rencontrées en pratique clinique et d'améliorer la capacité du système à gérer des requêtes plus spécifiques et nuancées.

L'ensemble de ces données synthétiques joue un rôle essentiel dans l'amélioration du système RAG. En enrichissant la diversité des formulations et des contextes cliniques, elles permettent d'augmenter la qualité du retrieval, de réduire les erreurs liées aux variations linguistiques et d'améliorer la pertinence globale des réponses générées. Cette étape contribue ainsi directement à la robustesse et à la performance du système dans des conditions proches d'une utilisation réelle.

Module NLP

Le module de traitement automatique du langage naturel (NLP) constitue une étape fondamentale dans l'architecture globale du système. Son rôle principal est d'assurer la compréhension et l'interprétation des requêtes formulées en langage naturel par l'utilisateur. Dans un contexte médical, cette étape est particulièrement importante car les questions peuvent être formulées de manière très variée, parfois imprécise, tout en faisant référence à des concepts médicaux complexes.

Le module NLP permet ainsi de transformer une requête utilisateur non structurée en une représentation exploitable par les différentes composantes du système, notamment le module de retrieval et le générateur de réponses.

La première étape du traitement consiste en un prétraitement du texte. Cette phase vise à normaliser les entrées utilisateur afin de réduire le bruit linguistique et d'améliorer la qualité des traitements ultérieurs. Le prétraitement inclut plusieurs opérations essentielles telles que la conversion de l'ensemble du texte en minuscules, la suppression des caractères spéciaux et des éléments inutiles, ainsi que le nettoyage général du texte. Une étape de normalisation linguistique est également appliquée afin d'uniformiser les différentes formes d'expression et de réduire les variations non pertinentes dans les requêtes.

Une fois le texte prétraité, le système procède à une analyse des intentions (intent classification). Cette étape permet d'identifier le type de besoin exprimé par l'utilisateur. Dans le cadre de ce projet, plusieurs catégories d'intentions ont été définies afin de couvrir les principales demandes en oncologie. Le système peut ainsi reconnaître si la requête concerne un diagnostic, un protocole de traitement, une demande d'information sur le suivi des patients, les effets secondaires d'un traitement ou encore des questions relatives à un protocole thérapeutique spécifique. Cette classification permet d'orienter efficacement la recherche d'information vers les sections pertinentes de la base de connaissances.

Parallèlement à l'analyse des intentions, le module NLP effectue une extraction des entités médicales présentes dans la requête utilisateur. Cette étape permet d'identifier les éléments clés mentionnés dans la question afin de mieux comprendre son contexte clinique. Les entités extraites peuvent inclure différents types d'informations médicales telles que le type de cancer (par exemple cancer du sein ou cancer du poumon), les symptômes décrits par l'utilisateur, les médicaments ou traitements mentionnés, le stade tumoral lorsqu'il est précisé, ainsi que les organes concernés.

L'extraction de ces entités joue un rôle crucial dans l'amélioration de la pertinence du système de retrieval. En effet, elle permet de mieux cibler les documents à rechercher dans la base de connaissances et d'augmenter la précision des résultats retournés. Elle contribue également à une meilleure contextualisation des réponses générées par le modèle de langage.

Ainsi, le module NLP agit comme une interface intelligente entre l'utilisateur et le système RAG. Il transforme des requêtes libres en informations structurées exploitables, tout en assurant une compréhension fine du besoin exprimé. Cette étape constitue donc un élément essentiel pour garantir la performance globale du système et la qualité des réponses fournies.

Conception et Architecture du système

Architecture globale du système

Le système est structuré en cinq couches interdépendantes. La première couche regroupe les sources officielles marocaines, notamment le guide des protocoles 2024, les protocoles thérapeutiques et les scénarios patients fictifs. La deuxième couche assure la construction manuelle de la base de connaissances : les données sont extraites manuellement depuis les documents sources et structurées en entrées JSON catégorisées avec mots-clés, sans recours à une bibliothèque de parsing automatique. La troisième couche implémente un module de retrieval hybride combinant la recherche sémantique par Sentence-BERT avec indexation FAISS et la recherche lexicale BM25, suivies d'une fusion Top-k pondérée selon la formule $\text{score} = \alpha \cdot \text{sem}(q,d) + (1-\alpha) \cdot \text{bm25}(q,d)$. La quatrième couche constitue le cœur du pipeline RAG : un prompt enrichi est soumis en parallèle aux trois modèles de génération — TinyLlama 1.1B pour la génération principale, Flan-T5 pour la génération comparative seq2seq et Qwen 2.5 pour la génération alternative multilingue — dont les sorties sont ensuite évaluées par les métriques BLEU, ROUGE et BERTScore. Enfin, la cinquième couche expose une interface web offrant un chat conversationnel, une visualisation du parcours patient, un upload de nouveaux documents PDF et un tableau de bord de comparaison des métriques par modèle.




Figure 1: Architecture globale de système

Pipeline RAG : flux d'exécution

Le pipeline RAG s'articule en sept étapes séquentielles. La question de l'utilisateur, formulée en français ou en arabe, est d'abord soumise à un prétraitement NLP comprenant le nettoyage et l'encodage vectoriel par Sentence-BERT. Le vecteur obtenu alimente simultanément deux modules de recherche : une recherche sémantique par similarité cosinus et une recherche lexicale BM25. Les résultats des deux branches sont fusionnés selon la formule $\text{score} = \alpha \cdot \text{sem}(q,d) + (1-\alpha) \cdot \text{bm25}(q,d)$ et re-rankés pour sélectionner les cinq documents les plus pertinents. Ces documents constituent le contexte injecté dans un prompt enrichi, lequel est soumis en parallèle aux trois modèles — TinyLlama 1.1B pour la génération principale auto-régressive, Flan-T5 pour la génération comparative seq2seq, et Qwen 2.5 pour la génération alternative multilingue. La réponse finale, structurée, simplifiée et sourcée, est accompagnée d'un avertissement explicite précisant l'absence de diagnostic médical direct.




Figure 2: Pipeline RAG-flux d'exécution

Technologies et Outils du Projet

La réalisation de ce projet a nécessité l'utilisation d'un ensemble de technologies couvrant le développement web, le traitement automatique du langage naturel, la recherche d'information et l'intelligence artificielle générative. L'architecture adoptée suit une approche Full-Stack, avec une séparation claire entre le backend, le frontend et le pipeline de traitement des données.

Langage de Programmation Principal

➤ Python

Python a été utilisé comme langage principal pour le développement du backend, la construction du pipeline NLP, l'indexation des données, les scripts d'analyse et les expérimentations liées au Machine Learning. Son écosystème riche en bibliothèques spécialisées en intelligence artificielle en fait un choix particulièrement adapté aux applications RAG.

Backend

➤ FastAPI



FastAPI est un framework web Python moderne permettant de développer des APIs rapides et performantes. Il est utilisé pour exposer la logique du système via des endpoints RESTful et gérer les interactions entre l'interface

Figure 3: FASTAPI utilisateur et les modules internes du projet.

➤ Uvicorn



Uvicorn est un serveur ASGI utilisé pour exécuter l'application FastAPI. Il permet de gérer les requêtes de manière asynchrone et d'améliorer les performances du backend.

Figure 4: UNICORN

➤ Pydantic



Pydantic est utilisé pour la validation et la sérialisation des données échangées par l'API. Il garantit que les requêtes et les réponses respectent les structures attendues.

Figure 5: Pydantic

Frontend

➤ React



React est utilisé pour développer l'interface utilisateur interactive de l'application. Il permet de créer des composants réutilisables et une expérience utilisateur dynamique.

Figure 6: REACTJS

➤ **Vite**



Figure 7: VITE

Vite sert d'outil de build et de serveur de développement pour le frontend. Il offre un démarrage rapide du projet et des mises à jour instantanées pendant le développement.

➤ **Tailwind CSS**



Figure 8: Tailwind CSS

Tailwind CSS est un framework CSS orienté utilitaires qui facilite la création d'interfaces modernes et responsives avec un style cohérent.

➤ **JavaScript**

JavaScript est utilisé pour la logique applicative du frontend et l'interaction avec l'API backend.

Pipeline de Données et NLP

➤ **Pandas**

Pandas est utilisé pour manipuler et analyser les données tabulaires, notamment les fichiers CSV contenant les informations oncologiques.

➤ **Scikit-learn**

Scikit-learn est utilisé pour certaines tâches de classification, d'évaluation et de prétraitement des données dans le pipeline NLP.

Sentence-Transformers / Hugging Face Transformers

➤ **Sentence-Transformers / Hugging Face Transformers**

Ces bibliothèques sont utilisées pour générer des représentations vectorielles (embeddings) des documents médicaux et des requêtes utilisateur. Les embeddings permettent de capturer le sens sémantique des textes et constituent la base de la recherche sémantique dans le système RAG. Grâce à cette approche, le système peut retrouver des documents pertinents même lorsque les mots utilisés dans la requête diffèrent de ceux présents dans la base de connaissances.

➤ **FAISS (Facebook AI Similarity Search)**

FAISS est une bibliothèque développée par Meta permettant d'effectuer des recherches rapides de similarité dans des espaces vectoriels de grande dimension. Dans ce projet, elle est utilisée pour indexer les embeddings générés par Sentence-BERT et retrouver efficacement les documents les plus proches sémantiquement de la requête utilisateur.

➤ **BM25 (Best Matching 25)**

BM25 est un algorithme de recherche d'information basé sur les mots-clés. Il permet d'évaluer la pertinence d'un document en fonction de la fréquence et de l'importance des termes recherchés. Dans ce projet, BM25 est utilisé pour effectuer une recherche lexicale au sein de la base de connaissances oncologique. Cette méthode est particulièrement efficace pour les requêtes contenant des termes médicaux précis, des noms de traitements ou des protocoles spécifiques.

➤ Recherche Hybride (BM25 + FAISS)

Afin d'améliorer la qualité du retrieval, une approche hybride a été adoptée. Les résultats obtenus par BM25 et par la recherche sémantique basée sur FAISS sont combinés à l'aide d'une méthode de fusion telle que le **Weighted Scoring** ou le **Reciprocal Rank Fusion (RRF)**. Cette combinaison permet de tirer parti à la fois de la précision de la recherche lexicale et de la capacité de la recherche sémantique à comprendre le sens des requêtes, améliorant ainsi la pertinence globale des documents récupérés

Modèles de Langage (LLM)

Le projet intègre trois modèles de langage afin de comparer leurs performances dans un contexte médical spécialisé :

- **TinyLlama 1.1B** : modèle causal auto-régressif compact, utilisé comme modèle de génération principale pour ses bonnes capacités de raisonnement et sa cohérence textuelle, tout en restant déployable sans GPU dédié.
- **Flan-T5** : modèle seq2seq fine-tuné sur un large ensemble de tâches d'instruction, apprécié pour sa capacité à suivre des consignes précises et à reformuler clairement les informations médicales.
- **Qwen 2.5** : modèle causal multilingue, utilisé pour la génération de réponses détaillées et structurées, avec de bonnes performances sur des requêtes spécialisées.

Ces trois modèles sont intégrés à parité dans l'architecture RAG et produisent leurs réponses à partir des documents récupérés dans la base de connaissances oncologique, permettant un benchmarking comparatif objectif sur les mêmes requêtes et le même contexte.

Outils de Développement et Gestion de Projet

➤ Git

Git est utilisé pour le contrôle de version et le suivi des modifications du code source.

➤ npm

npm gère les dépendances JavaScript du frontend, notamment React et Vite.

➤ pip

pip est utilisé pour installer et gérer les bibliothèques Python nécessaires au projet.

➤ Virtualenv (.venv)

Un environnement virtuel Python a été utilisé afin d'isoler les dépendances du projet et d'assurer la reproductibilité de l'environnement de développement.

➤ ESLint

ESLint permet d'analyser le code JavaScript et d'identifier les problèmes de qualité ou de style dans le frontend.

Formats de Données Utilisés

- **JSON** : utilisé pour les échanges de données entre le frontend et le backend, ainsi que pour certains fichiers de configuration et de résultats.
- **CSV** : utilisé pour le stockage des données tabulaires de la base de connaissances oncologique.
- **Markdown (.md)** : utilisé pour la documentation technique et les notes du projet.

Conclusion

L'ensemble de ces technologies forme une architecture cohérente et moderne, adaptée à la conception d'un assistant médical intelligent basé sur le NLP et le RAG. Le choix de ces outils permet d'assurer à la fois la performance du système, la qualité du traitement des données et une expérience utilisateur fluide.

Module de Retrieval

Le module de retrieval constitue une composante essentielle du système RAG développé dans ce projet. Son rôle principal est d'identifier, au sein de la base de connaissances oncologique, les documents les plus pertinents en réponse à une requête utilisateur. Cette étape est déterminante, car la qualité des informations récupérées influence directement la pertinence et la fiabilité de la réponse générée par le modèle de langage.

Afin d'améliorer la performance globale du système, une approche hybride a été adoptée. Cette approche combine deux méthodes complémentaires de recherche d'information : la recherche lexicale basée sur BM25 et la recherche sémantique basée sur les embeddings.

La première méthode repose sur l'algorithme BM25 (Best Matching 25), largement utilisé dans les systèmes de recherche d'information. BM25 permet d'évaluer la pertinence d'un document par rapport à une requête en fonction de la fréquence des mots-clés et de leur importance dans le corpus. Dans le cadre de ce projet, BM25 est particulièrement efficace pour traiter les requêtes contenant des termes médicaux précis ou des expressions spécifiques issues des protocoles oncologiques. Cette méthode présente plusieurs avantages, notamment sa rapidité d'exécution, sa simplicité de mise en œuvre et sa bonne performance sur les requêtes exactes ou techniques.

Cependant, la recherche basée uniquement sur les mots-clés présente certaines limites, notamment lorsqu'il s'agit de requêtes formulées de manière différente des documents sources. Pour pallier cette limitation, une deuxième approche basée sur la recherche sémantique a été intégrée.

Cette approche repose sur l'utilisation de Sentence-BERT, un modèle de langage capable de transformer les phrases en représentations vectorielles appelées embeddings. Ces embeddings permettent de capturer le sens global des phrases plutôt que de se limiter à la correspondance exacte des mots. Ainsi, deux phrases formulées différemment mais ayant un sens similaire peuvent être rapprochées dans l'espace vectoriel.

Une fois les embeddings générés, la similarité entre la requête utilisateur et les documents de la base de connaissances est calculée à l'aide de FAISS (Facebook AI Similarity Search), une bibliothèque

optimisée pour la recherche de similarité dans des espaces vectoriels de grande dimension. Le pipeline de recherche sémantique peut être résumé comme suit : la question utilisateur est transformée en embedding, puis comparée aux embeddings des documents stockés dans l'index FAISS afin de récupérer les documents les plus proches sémantiquement (Top-k documents).

Afin d'améliorer encore la qualité des résultats, une stratégie de fusion hybride a été mise en place. Cette stratégie combine les résultats obtenus par BM25 et ceux issus de la recherche sémantique. Deux méthodes principales ont été envisagées : le Weighted Scoring et le Reciprocal Rank Fusion (RRF). Le Weighted Scoring consiste à attribuer des poids aux scores des deux méthodes afin d'obtenir un score final combiné, tandis que le RRF repose sur un système de classement qui fusionne les positions des documents dans les différents résultats.

Cette approche hybride permet de bénéficier des avantages des deux méthodes. BM25 assure une excellente précision sur les termes exacts, tandis que la recherche sémantique permet de mieux gérer les variations linguistiques et les reformulations. La combinaison des deux améliore significativement la robustesse du système de retrieval et augmente la probabilité de récupérer les documents les plus pertinents, même dans des cas de requêtes complexes ou ambiguës.

Ainsi, le module de retrieval joue un rôle central dans l'architecture globale du système RAG, en assurant une sélection efficace et pertinente des informations médicales nécessaires à la génération des réponses.

Architecture RAG

Le système développé dans ce projet repose sur une architecture de type Retrieval-Augmented Generation (RAG), qui constitue aujourd'hui l'une des approches les plus efficaces pour améliorer la fiabilité des modèles de langage dans des domaines spécialisés tels que la médecine. Cette architecture combine deux composantes principales : un module de récupération d'information (retrieval) et un modèle de génération de texte (LLM), permettant ainsi de produire des réponses à la fois pertinentes, contextuelles et basées sur des sources fiables.

Le fonctionnement global du système suit un pipeline structuré en plusieurs étapes successives, chacune jouant un rôle précis dans le traitement de la requête utilisateur.

La première étape correspond à la réception de la question formulée par l'utilisateur. Cette question est exprimée en langage naturel et peut porter sur différents aspects de l'oncologie, tels que le diagnostic, les protocoles thérapeutiques ou les effets secondaires des traitements.

Ensuite, la requête subit une phase de prétraitement NLP. Cette étape permet de nettoyer et normaliser le texte afin de faciliter son traitement par les modules suivants. Elle inclut notamment la suppression des caractères inutiles, la normalisation linguistique et l'analyse initiale de la structure de la phrase.

Après cette étape, la question est transformée en représentation vectorielle à l'aide d'un modèle d'embedding. Cette représentation permet de capturer le sens sémantique de la requête et de la comparer efficacement avec les documents de la base de connaissances.

Le système procède ensuite à une double phase de recherche d'information. D'une part, une recherche lexicale est effectuée à l'aide de l'algorithme BM25 afin d'identifier les documents contenant des termes clés pertinents. D'autre part, une recherche sémantique est réalisée à l'aide de FAISS, qui exploite les embeddings générés par Sentence-BERT pour retrouver les documents les plus proches sur

le plan sémantique. Cette combinaison permet de maximiser la couverture et la pertinence des résultats récupérés.

Les résultats obtenus à partir de ces deux approches sont ensuite fusionnés afin de produire un classement unifié. Cette étape de fusion permet de combiner les avantages de la recherche lexicale et de la recherche sémantique, tout en améliorant la robustesse du système face aux variations linguistiques et aux formulations différentes des requêtes.

Une fois les documents les plus pertinents identifiés, le système sélectionne les Top-K résultats afin de constituer un contexte pertinent et limité. Ce contexte est ensuite utilisé pour construire un prompt enrichi, qui sera transmis au modèle de langage.

Le modèle de langage (LLM) génère alors la réponse finale en s'appuyant uniquement sur les informations fournies dans le contexte récupéré. Cette étape permet de garantir que la réponse est cohérente, structurée et alignée avec les connaissances de la base documentaire.

Enfin, la réponse générée est affichée à l'utilisateur via l'interface du système, accompagnée éventuellement des informations contextuelles utilisées.

L'architecture RAG mise en place présente plusieurs avantages majeurs. Elle permet notamment de réduire significativement les hallucinations des modèles de langage en ancrant les réponses dans des documents réels. Elle améliore également la précision des réponses en combinant recherche lexicale et sémantique, tout en offrant une meilleure adaptabilité aux différentes formulations des requêtes utilisateurs. Ainsi, cette architecture garantit un équilibre entre performance, fiabilité et pertinence dans le domaine sensible de l'oncologie.

Modèles de Langage Utilisés (LLM)

Les grands modèles de langage (Large Language Models - LLM) constituent la composante générative principale de l'architecture Retrieval-Augmented Generation (RAG) développée dans ce projet. Leur rôle consiste à générer des réponses en langage naturel à partir du contexte récupéré par le module de retrieval, tout en assurant une présentation claire, structurée et adaptée au domaine médical.

Dans ce projet, plusieurs modèles de langage ont été utilisés et comparés afin d'évaluer leurs performances dans un contexte spécialisé en oncologie. L'objectif principal de cette comparaison est d'identifier le modèle le plus adapté en termes de pertinence des réponses, de qualité linguistique et de cohérence avec les documents médicaux fournis.

Les modèles sélectionnés sont les suivants :

- **TinyLlama 1.1B** : modèle causal auto-régressif compact dérivé de l'architecture LLaMA, développé pour offrir de bonnes capacités de génération textuelle avec un empreinte mémoire réduite. Malgré sa taille limitée à 1,1 milliard de paramètres, il produit des réponses cohérentes et détaillées lorsqu'il est guidé par un contexte documentaire pertinent, ce qui en fait un choix adapté à un déploiement local sans GPU dédié.
- **Flan-T5** : modèle basé sur l'architecture T5 (Text-To-Text Transfer Transformer), optimisé par fine-tuning sur un large ensemble de tâches d'instruction. De nature seq2seq, il se distingue par sa stabilité, sa capacité à suivre des instructions précises et ses bonnes performances dans les tâches de résumé, d'explication et de reformulation structurée.
- **Qwen 2.5** : modèle causal développé par Alibaba Cloud, reconnu pour ses performances en compréhension multilingue et en génération de texte. Il se distingue par sa capacité à produire

des réponses bien structurées et adaptées à différents types de requêtes, y compris dans des domaines spécialisés.

L'intégration de ces trois modèles permet de réaliser un benchmarking comparatif dans un environnement RAG. Chaque modèle est évalué sur la base des mêmes requêtes utilisateur et du même contexte récupéré, afin de garantir une comparaison équitable.

Dans le cadre de ce projet, les modèles ne fonctionnent pas de manière autonome. Ils sont intégrés dans une architecture RAG, ce qui signifie que leurs réponses sont générées à partir des documents pertinents récupérés dans la base de connaissances oncologique. Cette approche permet de réduire les hallucinations et d'améliorer la fiabilité des réponses, en particulier dans un domaine critique comme la médecine.

Les principaux critères d'évaluation utilisés pour comparer ces modèles incluent la pertinence des réponses générées, la qualité de la reformulation, la cohérence avec le contexte médical fourni, ainsi que la clarté pédagogique des explications. Les métriques retenues sont le score BLEU, le score ROUGE et le BERTScore, appliqués de manière identique aux trois modèles afin de garantir une comparaison objective.

En conclusion, l'utilisation combinée de TinyLlama 1.1B, Flan-T5 et Qwen 2.5 permet d'explorer différentes approches de génération de texte — modèle causal compact, seq2seq fine-tuné et modèle multilingue — et d'optimiser les performances globales du système RAG en fonction des contraintes du domaine médical.

Évaluation du Système

L'évaluation de notre système a été menée sur deux axes complémentaires afin de mesurer séparément la qualité de la **recherche documentaire** et la qualité de la **génération de réponses**.

- **Évaluation de la recherche (retrieval).** Le module de recherche hybride combine une recherche sémantique (FAISS) et une recherche lexicale (BM25), pondérées par un coefficient α . Pour déterminer la valeur optimale de α , nous avons réalisé un *alpha sweep* sur un jeu de questions de test, en évaluant trois métriques standard de recherche d'information : le **Hit Rate@5** (proportion de questions pour lesquelles le bon document figure dans le top-5), le **MRR** (Mean Reciprocal Rank, qui récompense le rang du premier document pertinent) et la **Precision@5**. Cette analyse a permis d'identifier la valeur de α offrant le meilleur compromis entre pertinence sémantique et correspondance lexicale.




Figure 9 : Évaluation de la recherche (retrieval).

- **Évaluation de la génération (LLM).** La qualité des réponses générées a été évaluée en comparant trois modèles de langage sur un jeu de questions de référence (*gold standard*). Nous avons utilisé des métriques de similarité textuelle — **BLEU**, **ROUGE-L** et **BERTScore** — par rapport aux réponses de référence, ainsi que la **latence** moyenne de chaque modèle. À ces métriques s'ajoutent des indicateurs RAG sans référence calculés par similarité cosinus (SBERT) : la **faithfulness** (ancrage de la réponse dans le contexte récupéré, pour détecter les hallucinations), la **relevance** (adéquation de la réponse à la question) et la **context relevance** (pertinence des documents récupérés). Cette triade permet de distinguer les erreurs dues à la recherche de celles dues à la génération.

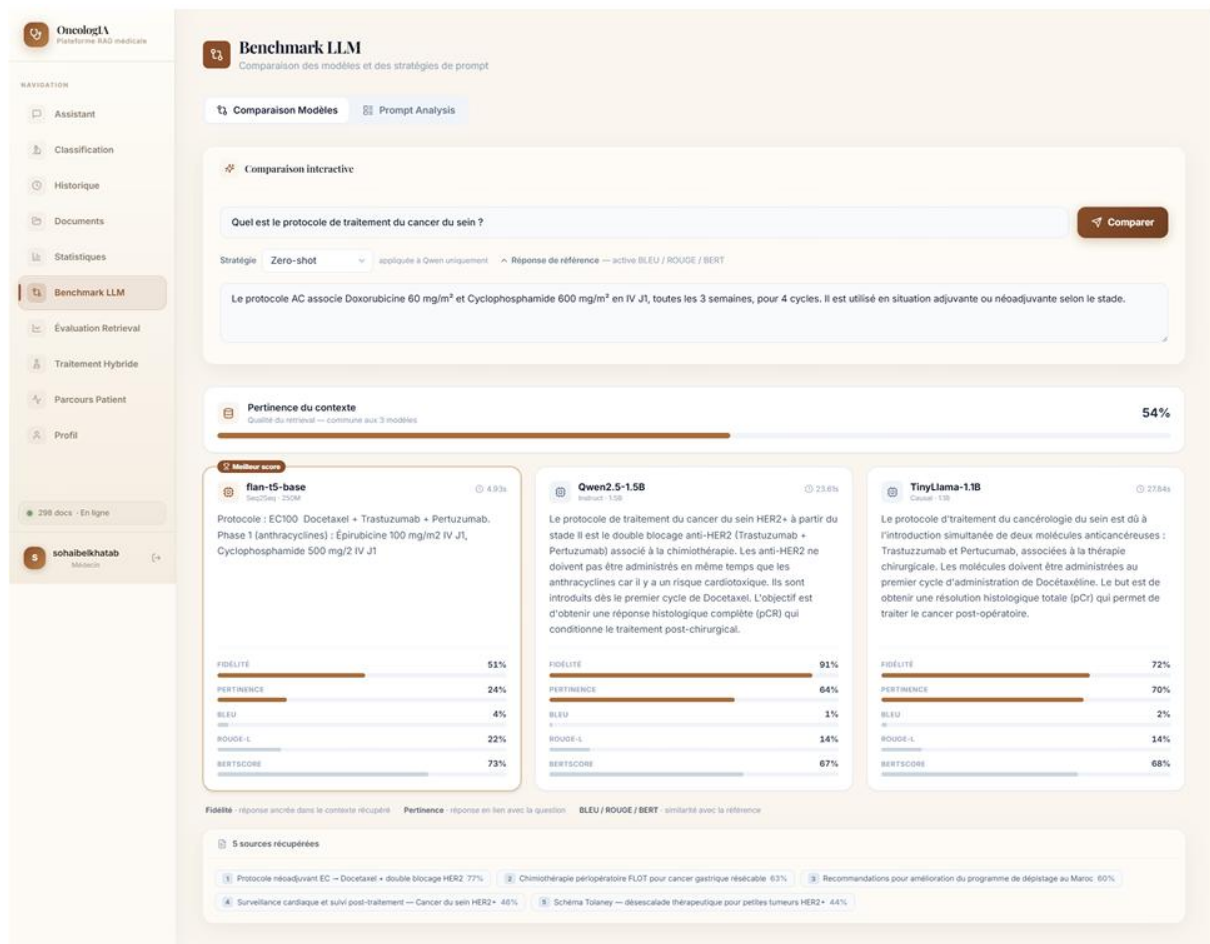


Figure 10 : Évaluation de la génération (LLM).

Les résultats de ces évaluations sont consultables directement dans l'interface via une page de visualisation dédiée présentant les courbes de métriques et un tableau de scores détaillé.

Interface Web

Afin de rendre le système exploitable par un utilisateur final (médecin), nous avons développé une interface web complète nommée **OncologIA**. Le frontend est construit avec **React** (bundler Vite) et communique avec le backend **FastAPI** via une API REST. L'accès est protégé par un système d'**authentification** : l'utilisateur doit se connecter depuis une page de login avant d'accéder à la plateforme.

Une fois connecté, l'utilisateur navigue à travers une **barre latérale** (sidebar) qui donne accès à l'ensemble des fonctionnalités. Un indicateur d'état y affiche en temps réel la disponibilité du système (statut « en ligne / hors ligne » et nombre de documents indexés). L'interface est organisée en plusieurs modules :

- **Assistant** : interface de chat conversationnel où l'utilisateur pose ses questions médicales et reçoit une réponse générée par le pipeline RAG, accompagnée des sources documentaires utilisées ;



Figure 11 :Assistant

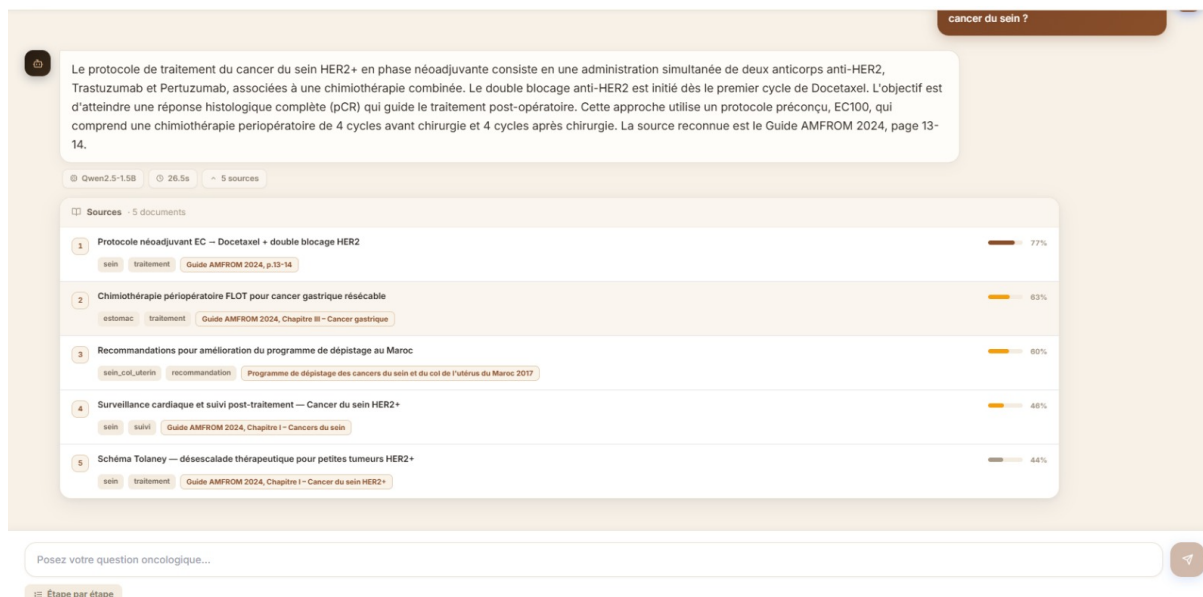


Figure 12:Assistant Avec Resources

- **Historique** : consultation des requêtes et réponses passées ;

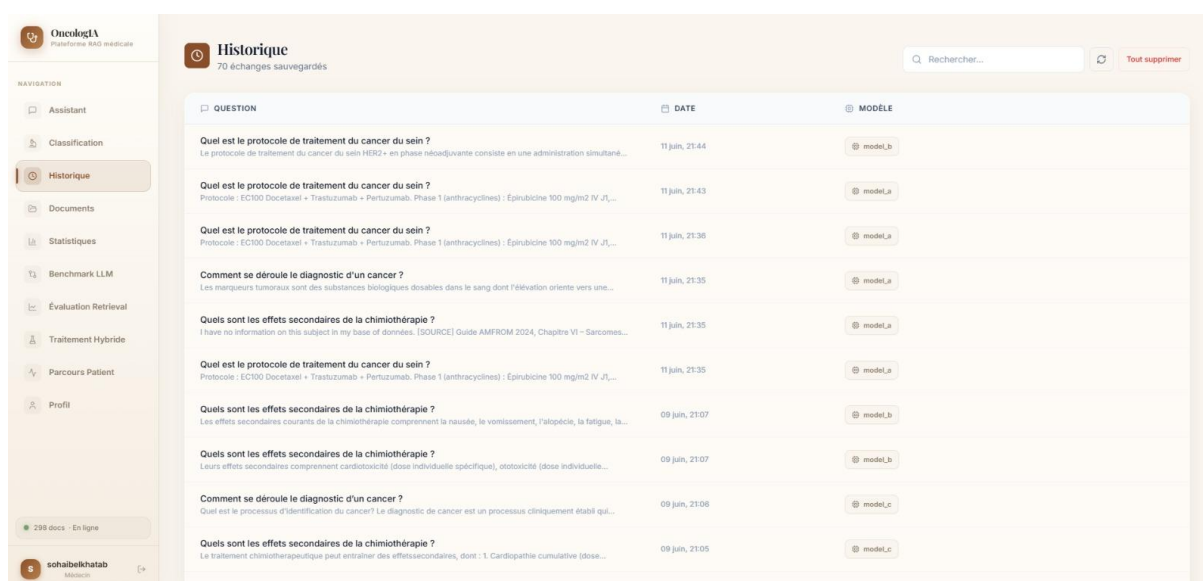


Figure 13 : Historique

- **Documents** : gestion et consultation de la base documentaire, avec possibilité d'uploader de nouveaux PDF ;

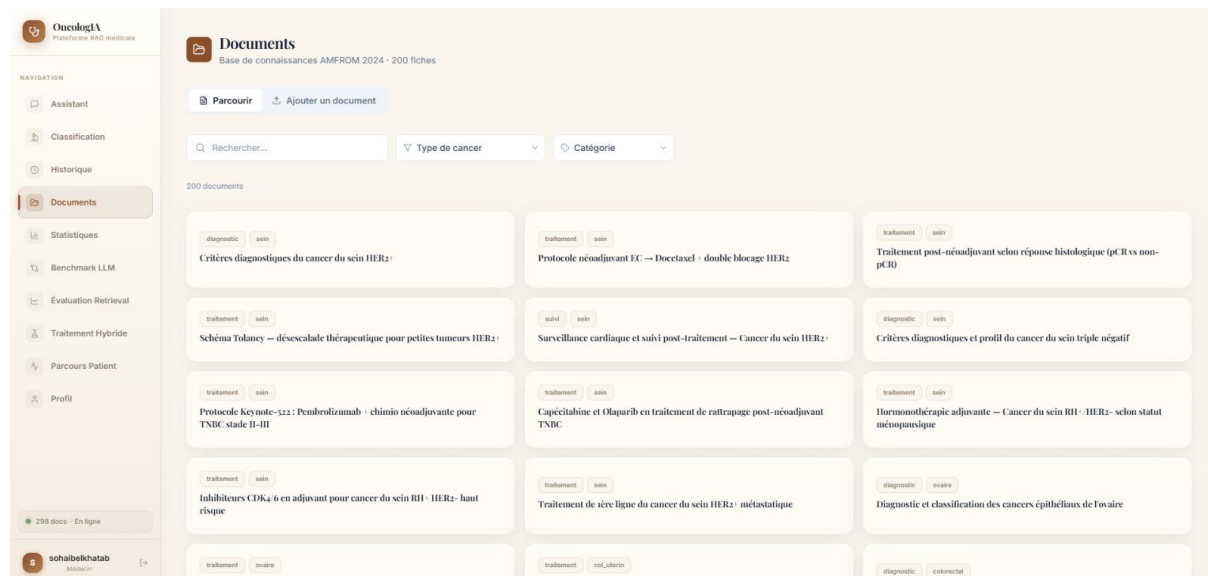



Figure 14 : Documents



- **Statistiques** : tableau de bord visualisant les indicateurs de la base de connaissances ;




Figure 15 : Statistiques

- **Benchmark LLM** : comparaison côte à côte des modèles de génération ;

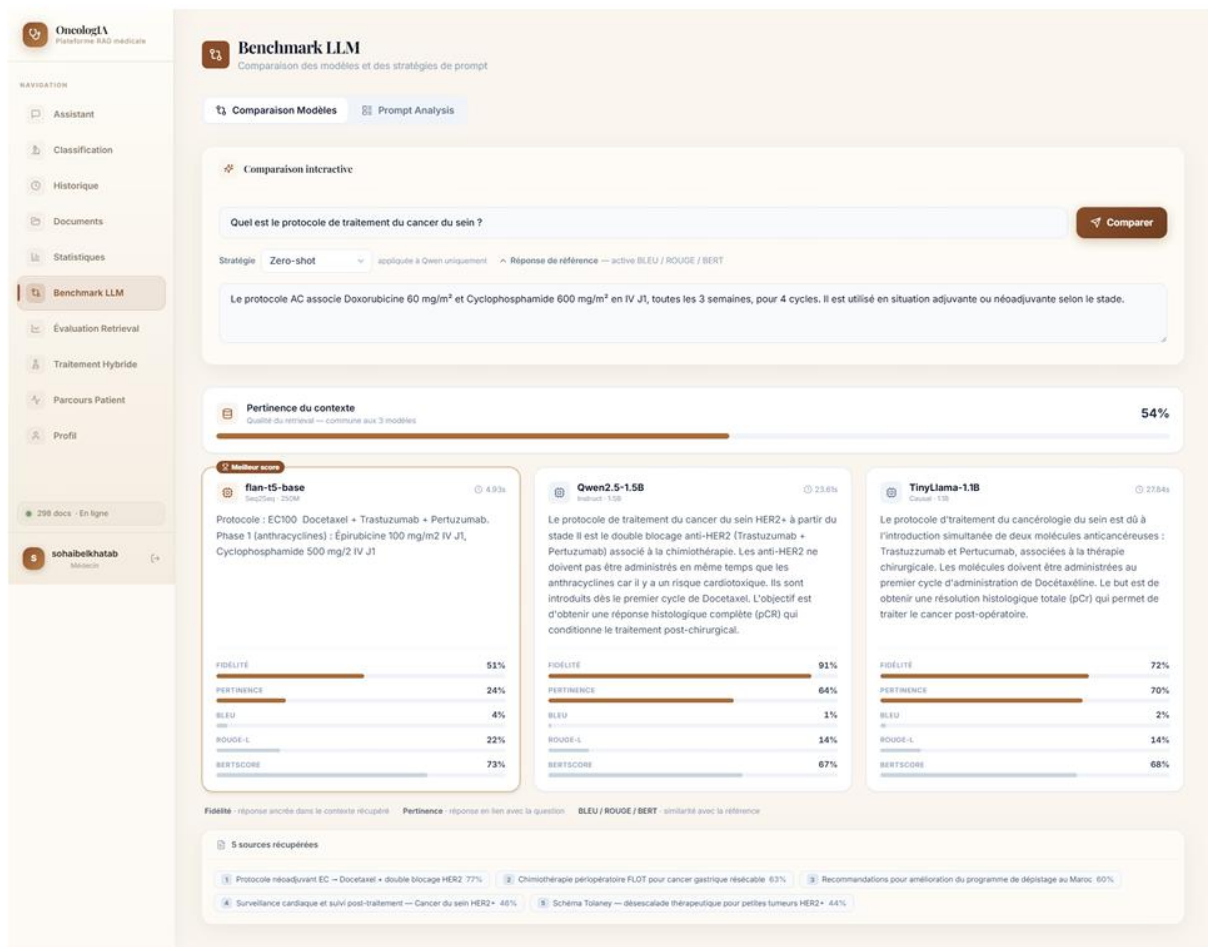


Figure 16: Benchmark LLM

- **Évaluation Retrieval** : visualisation des métriques de recherche (alpha sweep) ;




Figure 17 :Évaluation Retrieval

- **Traitement Hybride** : démonstration de la recherche hybride FAISS + BM25 ;

Figure 18 : Traitement Hybride

- **Parcours Patient** : suivi du parcours de soins ;

Figure 19 : Parcours Patient

- **Profil** : informations du compte utilisateur.

Figure 20 : Profil

L'interface adopte une **charte graphique sobre et médicale** (tons clairs, typographie soignée), pensée pour offrir une expérience claire et professionnelle adaptée à un usage clinique.

Limites du Projet

Malgré les résultats encourageants, notre système présente plusieurs limites qu'il convient de souligner.

1. Taille et couverture de la base de connaissances. Le système repose sur une base documentaire limitée, centrée sur le domaine de l'oncologie. Les réponses générées ne sont donc fiables que pour les sujets couverts par les documents indexés ; toute question portant sur un domaine ou une pathologie absente de la base risque de produire une réponse incomplète ou non pertinente.

2. Performance et ressources de calcul. Les modèles de langage sont exécutés en local sur **CPU**, ce qui entraîne une **latence élevée** lors de la génération des réponses, en particulier pour le benchmark qui exécute plusieurs modèles successivement. Cette contrainte limite l'usage en temps réel et nécessiterait, pour un déploiement à grande échelle, une infrastructure GPU.

3. Évaluation sur un échantillon réduit. L'évaluation de la recherche et de la génération a été réalisée sur un **nombre restreint de questions de test** et un *gold standard* limité. Les métriques obtenues (Hit Rate@5, MRR, BLEU, ROUGE-L, BERTScore) donnent une bonne indication de la qualité, mais ne sont pas statistiquement représentatives de l'ensemble des cas d'usage possibles.

4. Limites des métriques automatiques. Les métriques de similarité textuelle (BLEU, ROUGE-L) mesurent un chevauchement lexical avec la réponse de référence, mais évaluent imparfaitement la **justesse médicale** réelle d'une réponse. Une validation par des **experts médicaux** serait indispensable avant tout usage clinique.

5. Risque d'hallucination et responsabilité. Comme tout système basé sur des LLM, le modèle peut produire des **informations erronées ou inventées (hallucinations)**, malgré l'ancrage des réponses dans les documents récupérés (faithfulness). Le système est donc conçu comme un **outil d'aide à la décision** et ne saurait remplacer le jugement d'un professionnel de santé.

6. Aspects de sécurité et de confidentialité. Le traitement de données médicales sensibles soulève des enjeux de **confidentialité et de conformité réglementaire** (ex. RGPD) qui n'ont pas été pleinement traités dans le cadre de ce projet et constitueraient un prérequis pour une mise en production.

Conclusion

Au terme de ce projet, nous avons conçu et développé **Oncologia**, une plateforme complète d'assistance médicale fondée sur l'approche **RAG (Retrieval-Augmented Generation)** et appliquée au domaine de l'oncologie. L'objectif initial était de proposer un système capable de répondre à des questions médicales en s'appuyant non pas uniquement sur les connaissances internes d'un modèle de langage, mais sur une **base documentaire spécialisée et vérifiable**, afin de fournir des réponses contextualisées et traçables. Cet objectif a été atteint à travers une chaîne de traitement complète, allant de la préparation des données jusqu'à la mise à disposition d'une interface web exploitable par un utilisateur final.

Sur le plan technique, le projet a mobilisé plusieurs briques complémentaires du **traitement automatique du langage naturel (NLP)**. Nous avons d'abord constitué et nettoyé une base de connaissances médicale, puis mis en place une **recherche hybride** combinant une recherche sémantique (embeddings vectoriels indexés via **FAISS**) et une recherche lexicale (**BM25**), pondérées par un coefficient α optimisé expérimentalement. Cette composante de recherche alimente ensuite un module de **génération de réponses** s'appuyant sur des modèles de langage, avec la possibilité de comparer plusieurs modèles et plusieurs stratégies de *prompting* (zero-shot, few-shot, chain-of-thought). L'ensemble a été intégré dans une architecture **backend FastAPI / frontend React**, sécurisée par un système d'authentification et organisée autour de modules fonctionnels clairs : assistant conversationnel, classification, gestion documentaire, statistiques, benchmark et évaluation.

Une attention particulière a été portée à l'**évaluation rigoureuse** du système, menée sur deux axes complémentaires. La qualité de la recherche a été mesurée à l'aide de métriques standard de *retrieval* (**Hit Rate@5**, **MRR**, **Precision@5**) au moyen d'un *alpha sweep*, tandis que la qualité de la génération a été évaluée à l'aide de métriques de similarité textuelle (**BLEU**, **ROUGE-L**, **BERTScore**) et de métriques RAG sans référence (**faithfulness**, **relevance**, **context relevance**). Cette démarche d'évaluation a permis non seulement de quantifier les performances du système, mais aussi de **distinguer les erreurs provenant de la recherche de celles provenant de la génération**, offrant ainsi une compréhension fine de son comportement.

Ce travail nous a également confrontés à plusieurs **limites** — base de connaissances restreinte, coûts de calcul élevés en l'absence de GPU, échantillon d'évaluation réduit, limites intrinsèques des métriques automatiques et risque d'hallucination — qui rappellent qu'un tel système doit être envisagé comme un **outil d'aide à la décision** et non comme un substitut au jugement d'un professionnel de santé.

Au-delà de ses résultats, ce projet a constitué une expérience formatrice et fédératrice, nous permettant de mettre en pratique l'ensemble du cycle de développement d'une application d'intelligence artificielle moderne : de la préparation des données à l'ingénierie logicielle, en passant par la modélisation NLP et l'évaluation scientifique. Les **perspectives d'amélioration** sont nombreuses et prometteuses : élargissement et enrichissement de la base documentaire, passage à une infrastructure GPU pour réduire la latence, validation des réponses par des experts médicaux, renforcement de la sécurité et de la conformité réglementaire (RGPD) en vue d'un déploiement réel, et intégration de fonctionnalités avancées telles qu'un suivi plus poussé du parcours patient. En définitive, Oncologia démontre la **pertinence et le potentiel de l'approche RAG** pour des applications médicales spécialisées, tout en traçant une feuille de route claire vers un système plus robuste, plus fiable et véritablement déployable.